

基于混合SL与RL的 国标麻将AI

左欣颖 2500012921

Abstract

国标麻将是四人多轮不完美信息博弈，状态空间巨大，策略深度丰富。本文经过17个版本的训练尝试结合SL的行为克隆与近端策略优化（PPO）的RL。核心为通过KL散度惩罚项将RL策略锚定在SL预训练分布附近，在防止灾难性遗忘的同时允许有意义的探索。历经17个版本迭代，获得如下结论：(1) 纯RL从零训练完全无法学习（和牌率2%）；(2) 无SL锚定的RL出现严重策略崩塌（94%→46%）；(3) SL锚定的PPO在30局评估时达到100%和牌率，在100局评估时达到92%和牌率；(4) v15的对抗学习系统对SL Baseline获得0.650峰值胜率，为当前最优版本。

1. 引言

国标麻将（Chinese Standard Mahjong）依据国家体育总局1998年颁布的《中国麻将竞赛规则》，是四人参与的复杂不完美信息博弈。与日本立直麻将或广东麻将等简化变体不同，国标麻将要求和牌时至少达到8番，这一约束从根本上改变了策略空间——玩家不仅需要完成手牌组合，还必须有意地累积番种。

国标麻将AI开发面临以下核心挑战：(1) 状态空间巨大——34种牌 × 多方玩家 × 隐藏信息；(2) 决策阶段多样——摸牌、出牌、副露（吃碰杠）、和牌；(3) 8番起和限制要求非平凡的规划能力；(4) 不完美信息需要推断对手隐藏手牌与剩余牌墙分布。

本文系统探索了国标麻将AI的训练范式，从监督模仿学习逐步推进至混合SL-RL方法。历经17个版本迭代，每个版本引入或优化特定的架构组件。

2. 问题建模

2.1. 游戏机制

国标麻将使用144张牌，包含34种牌面类型：万（1–9万）、条（1–9条）、筒（1–9筒）、风牌（东南西北）、箭牌（中发白）、花牌（8张）。每位玩家初始13张手牌，轮流出牌摸牌。玩家可对他人弃牌做出吃、碰、杠等副露操作。当有玩家达成 ≥ 8 番的合法和牌型时游戏结束，或牌墙耗尽导致黄庄。

2.2. 建模

国标麻将是典型的4人不完全信息博弈，每位玩家仅能观测自身私有信息（手牌）及所有玩家的公开信息（副露、弃牌），无法获知对手手牌与牌墙顺序。我们采用 self-play 训练框架，四个玩家共享同一策略 π_θ 。在此框架下，游戏可形式化为部分可观测随机博弈（POSG），并通过参数共享简化为对称形式。

其数学定义如下：

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{O}, \mathcal{T}, \mathcal{R}, \Omega, \gamma \rangle \quad (1)$$

POSG 各元素定义如下：

- $\mathcal{S}$ ：完全信息状态空间。状态 $s \in \mathcal{S}$ 编码全部游戏信息——4家手牌（每人 1×34 向量，各牌持有数 0–4）、4家已露副露（吃/碰/杠的公开结构）、4家弃牌序列（河）、牌墙剩余牌

序、圈风与座风、当前阶段（摸牌/出牌/副露候选/结算）。SL 训练数据提供 s 的全量访问；RL 自弈时环境模拟器维护 s ，但不直接暴露给策略网络。

- $\mathcal{A}$: 动作空间, $|\mathcal{A}| = 235$ 个离散动作组成的有限集合, 包括: Pass(1)、Hu(1)、Play(34)、Chi(63)、Peng(34)、Gang(34)、AnGang(34)、BuGang(34)。每步以动作掩码 $\mathbf{m}(s, p) \in \{0, 1\}^{235}$ 约束输出至合法子集:

$$\mathcal{A}_{\text{legal}}(s, p) = \{a \in \mathcal{A} \mid \mathbf{m}_a(s, p) = 1\} \quad (2)$$

- $\mathcal{O} \subseteq \mathbb{R}^{6 \times 4 \times 9}$: 局部观测空间。各通道分别对应座风、圈风及四层手牌编码。
- $\Omega: \mathcal{S} \times \{0, 1, 2, 3\} \rightarrow \mathcal{O}$: 观测函数, 从完全状态提取玩家 p 的局部观测:

$$o_t^p = \Omega(s_t, p) \in \mathbb{R}^{6 \times 4 \times 9} \quad (3)$$

当前观测不编码对手手牌、弃牌历史、副露状态及牌墙信息, 这一局限将在第??节讨论。

- $\mathcal{T}: \mathcal{S} \times \mathcal{A}^4 \rightarrow \mathcal{S}$: 状态转移函数。给定当前状态 s_t 和四家联合动作 $\mathbf{a}_t = (a_t^0, a_t^1, a_t^2, a_t^3)$, 环境按国标麻将规则执行摸牌、出牌、副露优先级仲裁及和牌判定, 转移至 s_{t+1} 。
- $\mathcal{R}: \mathcal{S} \times \mathcal{A}^4 \rightarrow \mathbb{R}^4$: 奖励函数。采用稀疏终局奖励, 仅在局终产生非零值。设终局时玩家 p 的和牌番数为 f^p (未和牌则 $f^p = 0$), 奖励按以下规则分配:
 - 自摸: 和牌者 p 获 $3 \times (8 + f^p)$ 分, 其余三家各获 $-(8 + f^p)$ 分
 - 点炮: 和牌者 p 获 $(8 + f^p)$ 分, 点炮者 q 获 $-(8 + f^p)$ 分, 其余两家为 0
 - 黄庄: 全体获 0
 一局中 $\sum_p R^p = 0$, 满足零和性质。
- $\gamma = 0.98$: 折扣因子。

3. 方法

3.1. 模型结构

使用基于卷积神经网络 (CNN) 的 Actor-Critic 架构, 如图1所示。



Figure 1. CNN Actor-Critic 架构。策略头输出 235 维 logits 并经动作掩码约束; 价值头估计状态价值 $V(s)$ 。

模型使用 Kaiming 初始化, 所有卷积层采用 3×3 卷积核、步长 1、填充 1, 激活函数均为 ReLU。总参数量约 130 万, 模型文件体积约 5.2MB, 完全在 Botzone 的 50MB 存储限制内。

3.2. 行为克隆预训练

首先通过行为克隆在已有对局数据上训练策略网络。给定数据集中的状态-动作对 (s, a^*) , 最小化交叉熵损失:

$$\mathcal{L}_{\text{SL}} = -\mathbb{E}_{(s, a^*) \sim \mathcal{D}} [\log \pi_\theta(a^* | s)] \quad (4)$$

训练使用 Adam 优化器, 学习率 5×10^{-4} , 批量大小 1024, 训练 20 轮, 训练/验证集按 9:1 划分。SL 模型在验证集上达到 84% 的 Top-1 动作预测准确率。该模型冻结后同时作为 RL 初始化权重、SL 锚定参考策略和评估基线对手。

3.3. 强化学习优化

从SL预训练权重出发，采用近端策略优化算法(Schulman et al., 2017)进行自我对弈 (self-play) 训练。RL目标函数由策略损失、价值损失和熵奖励组成：

$$\mathcal{L}_{\text{PPO}} = \mathcal{L}_{\text{policy}} + c_v \mathcal{L}_{\text{value}} - c_e H(\pi_\theta) \quad (5)$$

其中 $\mathcal{L}_{\text{policy}} = -\mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$, $r_t = \frac{\pi_\theta(a_t | s_t)}{\pi_{\text{old}}(a_t | s_t)}$, A_t 通过广义优势估计 (GAE) 计算，参数为 $\gamma = 0.98, \lambda = 0.95$ 。

环境模拟4人自我对弈。终局奖励为和牌番数，不设中间过程奖励。每局对局的轨迹数据存入缓冲区，从中采样小批量数据进行4轮PPO更新。

3.4. 训练稳定化：从SL约束到受控RL优化

SL→RL精调的核心困难在于：RL通常需要通过偏离SL策略分布来获得更高回报，但在稀疏终局奖励下，这种偏离既缺乏稳定梯度信号，也难以区分“有益探索”与“破坏性漂移”。在无约束RL训练中，策略会迅速丧失和牌基础能力，性能从94%崩塌至46%（见第4节）。

这一现象表明训练过程存在两类典型失败模式：快速策略崩溃 (policy collapse) 与缓慢行为漂移 (gradual drift)。前者表现为策略迅速偏离SL行为分布并失去基本能力，后者则表现为在表面稳定的情况下逐渐偏离高质量行为模式。

3.4.1. 约束机制：防止策略快速崩溃

为防止策略在RL更新中快速偏离SL分布，在损失函数中加入KL约束项，使当前策略始终保持在SL策略附近：

$$\mathcal{L}_{\text{anchor}} = D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{SL}}) \cdot \alpha \quad (6)$$

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{PPO}} + \mathcal{L}_{\text{anchor}} \quad (7)$$

该约束使RL优化不再是在整个策略空间中自由搜

索，而是限制在SL策略分布的高概率区域附近进行更新，从而避免策略发生灾难性偏移。

实验表明，移除该约束会导致训练完全崩溃 (§4.2)，说明该机制是稳定训练的重要因素。

3.4.2. 行为校准：防止渐进性偏移

仅依靠KL约束可以防止大幅偏移，但在允许范围内，策略仍可能逐渐偏离SL的高质量行为模式。这种偏移通常不会立即导致性能崩溃，因此更难被检测。

为解决这一问题，在训练过程中引入行为克隆校准。在 self-play 对局中，每步决策时同步运行冻结 SL 模型前向推理，得到其 argmax 动作 $a_{\text{SL}}^* = \text{argmax}_a \pi_{\text{SL}}(a | s)$ ，与状态一同存入历史缓冲。PPO 更新时，从缓冲采样 30% (v15) 至 50% (v17) 的批次数据，以 SL 标签进行交叉熵校准：

$$\mathcal{L}_{\text{BC}} = -\mathbb{E}_{s \sim \mathcal{B}_{\text{hist}}} [\log \pi_\theta(a_{\text{SL}}^* | s)] \quad (8)$$

SL 标注在游戏过程中一次性产生、后续多次复用，不增加 PPO 更新步骤的额外推理开销。该机制的作用可理解为：在 RL 优化过程中持续“复述”SL 的行为结构，对抗稀疏奖励区间内的慢性漂移。

3.4.3. 训练过程控制：稳定性与可恢复性

上述两类机制主要作用于优化目标，但仍无法完全避免由高方差更新导致的偶发性能退化。因此，进一步在训练过程层面引入稳定控制机制。

首先，使用指数滑动平均参数作为评估模型：

$$\theta_{\text{ema}} \leftarrow 0.995\theta_{\text{ema}} + 0.005\theta \quad (9)$$

EMA用于平滑参数更新带来的噪声，使评估结果更稳定可靠。

其次，引入回滚机制。当模型性能持续下降并低于历史最优水平时，训练会自动恢复到最佳模型，并降低学习率，重置部分训练状态，使优化过程重新从稳定起点继续进行。该机制使训练过程具备一定

的可回退能力，避免性能退化的累积。

最后，维护一个策略池，保存若干历史表现较好的模型，用于增加后续训练中的策略多样性。

3.4.4. SL作为稳定参照

上述机制是针对不同类型的训练不稳定性逐层构建的解决方案：**KL**约束主要防止策略快速偏离，行为校准用于抑制缓慢退化，而**EMA**与回滚机制则保证训练过程在异常情况下仍可恢复。

该方法在v15中表现稳定：所有随机种子均未出现训练崩溃，平均峰值性能达到0.608，说明该约束机制能够在高方差RL环境中有效维持训练稳定性。

3.5. 多策略联赛训练系统

为进一步提升对抗稳健性，实现了基于Elo评分的联赛训练系统。联赛维护多样化的历史策略池，每轮训练从四类对手中动态采样：

- **40% 强对手**：Top-2 Elo对手 + 对当前策略胜率 > 0.55 的策略
- **30% 自我对弈**：与当前策略Elo差距 ± 30 以内的策略
- **20% SL/基线**：冻结SL模型及早期RL检查点，防止遗忘基础技能
- **10% 对抗者**：在难样本上训练的对抗策略，主动暴露当前策略弱点

联赛系统在v8版本中取得了最优竞争动态：Elo分布跨度187，峰值Elo 1587，KL范围0.09–0.15，训练全程零次稳定性触发器触发。

3.6. 实验变体

前述稳定化机制的组合方式产生了多个实验变体。表1归纳了两个代表性版本的配置差异，其性能对比见第4节。

v15（最优模型）：采用激进回滚策略——当胜率低于最佳超0.03或连续2次评估下降即触发回滚，5种

Table 1. 代表性实验变体配置对比

机制	v15	v17
KL锚定	软 缩 放： KL >0.10 时 $\times 2$ ， KL <0.05 时 $\times 0.5$	软 缩 放： KL >0.12 时 $\times 2$ ， KL <0.06 时 $\times 0.5$
BC校准	30% 批次混合	BC权重0.8 + 三层缓冲
EMA	0.995	0.995
回滚	激进： 0.03或2连 清空动量	> 放宽： 0.05且3连 降，清空动量
策略池 对抗训练	≥ 0.55 ，max 5 每200ep克 隆+训练	≥ 0.55 ，max 5 每200ep克隆+训练
KL安全 网	无（依赖回滚兜底）	EMA KL $> 0.15 \times$ 50ep 强制BC校准
回合数	3000 + 早停	3000（训练中）
峰值胜率	0.650 (s0@ep2400)， 5种子均值0.608	效果不佳

子平均每种子回滚16次；当滚动胜率 ≥ 0.55 时自动进入稳定化阶段（PPO轮数、学习率、熵系数均减半）。5种子NPU云端训练结果：峰值胜率均值0.608，最高单种子0.650，最终胜率均值0.542。

v17：受TD3+BC(Fujimoto and Gu, 2021)启发，尝试以 BC 权重 0.8 配合三层缓冲（BC/Dagger/难样本各 10万/2万/1.5万条）增强 SL 监督信号，同时将 KL 控制从固定锚定改为软缩放（ > 0.12 时 $\times 2.0$ ， < 0.06 时 $\times 0.5$ ）。然而训练效果不佳，原因可能在于三层缓冲合计的 SL 监督强度过高——Dagger 缓冲引入的当前策略分布数据与 BC 缓冲中的历史数据存在分布冲突，难样本的 $\times 2$ 加权进一步放大噪声，反而干扰了 RL 的稀疏奖励学习。

4. 讨论

本章围绕“如何在 SL 基线之上获得稳定提升”的问题展开。

4.1. RL 基于 SL 的提升

表2展示了从纯 SL 到不同 RL 变体的结果。

Table 2. SL 基线与 RL 变体对比

方案	最佳30局和牌率	100局和牌率
仅SL（冻结）	84%	—
RL随机初始化	2%	—
RL无锚定	94%→46%	—
增强基线（含锚定）	100%	92%
+ 特征扩展	67–96%	—
+ 自适应熵	83%	79%
+ 分离动作头	23%	—

纯 RL（随机初始化）的30局和牌率仅 2%，说明稀疏终局奖励完全不足以从零学习，SL 初始化是有必要的。含锚定的 RL 和牌率相比纯SL有明显提升，证明在 SL 先验附近存在 RL 可发掘的改进空间。

移除锚定的 RL 出现崩塌现象（94%→46%）。稀疏奖励无法在策略偏离 SL 信任区域后提供纠正信号。

在锚定基线上叠加特征扩展、自适应熵或分离动作头，无一超越基线。这些尝试的共同模式是：引入了更多可学习参数或自适应调度，但 2000 局的梯度信号不足以支撑这些额外自由度。

在该任务设定下，SL提供了可行策略的基础分布，RL的作用在于在该分布邻域内进行有限改进，而整体性能上限主要由策略稳定性决定。

4.2. 如何使提升稳定？

4.2.1. 锚定强度与退火

表3的结果表明，锚定强度需要控制在合适范围内。

当 $\alpha \in [0.01, 0.1]$ 时，模型的最佳和牌率保持稳定（93.3%），最终性能差异较小；当 α 增大至 0.5 时，性能明显下降（最终 76.7%），说明约束过强会限制策略更新幅度，从而影响改进效果。

学习率降低至 1×10^{-5} 时，最终和牌率提升至 93.3%，表明较小的参数更新步长有助于在锚定约

Table 3. 锚定强度与超参数选择

配置	最佳和牌率	最终和牌率
baseline ($\alpha=0.05, lr=5 \times 10^{-5}$)	93.3%	83.3%
$\alpha=0.01$	93.3%	86.7%
$\alpha=0.1$	93.3%	83.3%
$\alpha=0.5$	90.0%	76.7%
$lr=1 \times 10^{-5}$	96.7%	93.3%
退火 α	83.3%	73.3%

束下获得更稳定的优化结果，但在大规模评估中略低于基线配置，说明更新过慢可能影响策略适应性。

退火 α 的配置表现较差（73.3%）。结果表明，在训练早期减弱锚定约束后，策略容易发生分布偏移，且后续训练无法完全恢复到原有性能水平。因此，在当前设置下，锚定约束采用稳定保持而非逐步减弱的方式效果更好。

4.2.2. 回滚、EMA 与 BC 校准的组合效应

Table 4. v15 五种子训练结果

种子	峰值胜率	@回合	最终胜率	回滚次数
s0	0.650	2400	0.550	14
s1	0.588	200	0.580	14
s2	0.625	400	0.550	20
s3	0.588	2600	0.450	14
s4	0.588	1200	0.580	18
均值	0.608	—	0.542	16

表4以 v15 的 5 个种子训练结果验证了§3.4中稳定系统的综合效果。

所有种子均未发生灾难性崩溃，5 个种子峰值均值 0.608、标准差仅 0.026，验证了 EMA + 回滚组合能有效阻止不可逆退化。但各种子从峰值到最终普遍回落（均值 0.608→0.542），说明当前机制能防止崩塌但尚不能完全消除慢性性能衰减。

4.3. 无效的策略

在本文的实验环境下，有一些看似有效的策略并没有取得理想效果。

特征增强未带来提升。在锚定基线上添加副露、牌墙、弃牌历史等额外输入通道，和牌率降至 67–96%。可能原因包括：2000 局数据不足以学习更复杂的输入映射、CNN 架构难以有效融合异构特征、或额外维度引入了优化噪声。确切原因需进一步消融实验确定。

Suphx 组件迁移后性能下降。尝试将 Suphx 中的自适应熵与分离动作头引入本任务，但未带来性能提升。

(1) 自适应熵在 Suphx 中用于增强探索，但在本实验中将最佳和牌率从 100% 降至 83%。推测原因是 Suphx 的大规模对手池为随机探索提供了正向反馈，而本实验的小规模对手池中探索更多导致进入低回报区域。

(2) 分离动作头将出牌与副露拆分优化，和牌率降至 23%。观察到 KL 约束在此结构下失效，但不确定是结构拆分本身、优化超参不匹配还是 KL 梯度稀释导致。需更多消融来区分这些因素。

三层缓冲系统未达预期。v17 引入 BC、DAgger 与难样本三类缓冲（规模各 10 万/2 万/1.5 万条），以 BC 权重 0.8 混合训练，训练性能反而下降。需注意 v17 同时改变了 KL 缩放阈值、BC 机制和回滚策略，多变量混杂使得无法确定性能下降的主因。一种可能性是 BC 权重 0.8 配合三缓冲的监督强度压制了 RL 奖励信号；另一种是不同缓冲的数据分布不一致导致梯度冲突。

以上负向结果共同说明：在数据稀缺条件下，SL 锚定 + 适度 BC + 训练保护的组合优于引入过多额外结构复杂度的方案。

参考文献

J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms.

arXiv preprint arXiv:1707.06347, 2017.

S. Fujimoto and S. S. Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

J. Li, S. Koyamada, Q. Ye, G. Liu, C. Wang, R. Yang, L. Zhao, T. Qin, T.-Y. Liu, and H.-W. Hon. Suphx: Mastering mahjong with deep reinforcement learning. *arXiv preprint arXiv:2003.13590*, 2020.